

Die **Perfusiologie** stellt in der Rubrik Tutorials in Folge relevante Methoden für wissenschaftliche Arbeiten zur klinischen Perfusion und technischen Medizin vor.

## Statistik Teil 13: Lineare Regression



**Prof. Dr. Matthias Kohl**  
Department of Medical and Life Sciences  
Institute of Precision Medicine  
Hochschule Furtwangen  
Jakob-Kienzle-Str. 17, 78054 Villingen-Schwenningen (Germany)  
Phone: +49 (0) 7720 307-4635  
E-Mail: [matthias.kohl@hs-furtwangen.de](mailto:matthias.kohl@hs-furtwangen.de)  
[www.hs-furtwangen.de](http://www.hs-furtwangen.de) · [www.life-data-science.org](http://www.life-data-science.org)

M. Kohl, F. Münch

### Einführung

Die lineare Regression ist eines der am häufigsten angewendeten Verfahren in der Statistik. Es wird dabei untersucht, wie gut sich eine abhängige Variable (Response, Zielvariable) durch eine Linearkombination von unabhängigen Variablen (Regressoren, erklärende Variablen) beschreiben lässt. Der t-Test [1], die 1-Weg ANOVA [2] oder auch generell die Varianz- und Kovarianzanalyse (ANOVA und ANCOVA) sind Spezialfälle des linearen Modells. Wir werden in diesem Tutorial kurz das multiple lineare Modell mit den typischen Modellannahmen vorstellen. Unser Augenmerk liegt jedoch nicht auf der Theorie der linearen Modelle, hierzu gibt es eine ganze Reihe von Büchern, sondern darauf, welche speziellen Phänomene im Zusammenhang mit der linearen Regression auftreten können und was man bei der Anwendung von linearen Modellen in der Praxis beachten sollte.

### Einfache lineare Regression

Zur Einführung beginnen wir mit der sogenannten einfachen linearen Regression, um einige grundlegende Begriffe und Konzepte einzuführen (vgl. Abschnitt 8.2.1 in [3]). In diesem Fall soll die abhängige Variable  $y$  (Skalar) durch eine einzige unabhängige Variable  $x$  (Skalar) erklärt werden. Das Modell lautet

$$y = \beta_0 + \beta_1 x + \epsilon,$$

wobei es sich bei  $\epsilon$  um eine stochastische Fehlervariable handelt, die zufällige Schwankungen in der abhängigen Variable  $y$  erzeugt, die nicht durch den Regressor  $x$  erklärt werden können. Es geht demnach darum, eine Gerade mit Achsenabschnitt  $\beta_0$  und Steigung  $\beta_1$  zu schätzen. Man nennt  $\beta_0$  und  $\beta_1$  auch die Koeffizienten oder Parameter des Modells. Im Fall, dass es keine erklärenden Variablen gibt, reduziert sich dies auf das so genannte Lokationsmodell, welches im Regressionskontext auch Nullmodell (enthält 0 Regressoren) genannt wird.

$$y = \beta_0 + \epsilon$$

### Fazitbox

#### Pro und Contra lineare Regression:

##### Pro

- Es handelt sich um ein sehr flexibles statistisches Verfahren, welches in vielen Fällen angewendet werden kann.
- Wichtige Spezialfälle sind die Varianz- und die Kovarianzanalyse.
- Durch den Einsatz von Variablentransformationen lässt sich der Anwendungsbereich der linearen Regression sogar noch weiter ausdehnen.

##### Contra

- Ein gefittetes lineares Modell sollte immer einer gründlichen Modelldiagnostik unterzogen und auf seine Voraussetzungen geprüft werden.
- Das Bestimmtheitsmaß  $R^2$  sollte immer mit Vorsicht interpretiert werden, da es leicht zu manipulieren ist. Entsprechende Alternativen sollten zusätzlich berücksichtigt werden.
- Typische Phänomene, die im Zusammenhang mit der linearen Regression auftreten können, sollten in die Interpretation und Diskussion der Ergebnisse einbezogen werden.
- Liegen sehr viele Variablen vor und wird eine statistische Modellwahl durchgeführt, so sollte dies mit großer Sorgfalt und unter Verwendung einer internen oder externen Validierung erfolgen.

Für die Bestimmung der Koeffizienten wird üblicherweise die Methode der kleinsten Quadrate verwendet. Dies führt auf die geschätzten (gefitteten) Werte für die Koeffizienten, die üblicherweise mit einem „Hut“ versehen werden, also  $\hat{\beta}_0$  und  $\hat{\beta}_1$ . Entsprechend erhalten wir die geschätzten (gefitteten) Werte für  $\hat{y}$  als

$$\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x.$$

Dies sind folglich die Werte, die durch die gefittete Gerade für die abhängige Variable  $y$  vorhergesagt werden. Die Differenz  $y_i - \hat{y}_i$  ( $i = 1, \dots, n$ ) zwischen einem beobachteten Wert  $y_i$  und dem vorhergesagten Wert  $\hat{y}_i$  nennt man **Residuum**. Hieraus wird die **Summe der Residuenquadrate** RSS (residual sum of squares) berechnet

$$RSS = \sum (y_i - \hat{y}_i)^2.$$

Die RSS für das Modell vergleicht man mit der RSS des Nullmodells, welche man auch als **TSS** (total sum of squares) bezeichnet. Um festzustellen, ob  $x$  einen zusätzlichen Erklärungswert liefert, betrachtet man das Verhältnis von RSS zu TSS, wobei aus diesem Verhältnis das **Bestimmtheitsmaß**  $R^2$  abgeleitet wird als

$$R^2 = 1 - \frac{RSS}{TSS}.$$

Es ergibt sich hierfür immer eine Zahl im Bereich von 0 bis 1. Man erhält  $R^2 = 1$ , falls alle Beobachtungen  $y$  exakt auf der gefitteten Geraden liegen und  $R^2 = 0$ , falls  $x$  keinen Erklärungswert besitzt. Allgemeiner ausgedrückt, entspricht das  $R^2$  gerade dem Anteil der Variabilität in den Daten, der durch das Modell erklärt wird. Im Fall der einfachen linearen Regression, entspricht das  $R^2$  auch gerade dem Quadrat der Pearson-Korrelation [4]. Es ist zu beachten, dass das  $R^2$  generell leicht zu manipulieren ist. Zum Beispiel lässt sich das  $R^2$  alleine dadurch erhöhen, indem man weitere Regressoren ins Modell aufnimmt. Wir werden im nächsten Abschnitt daher auch noch weitere Möglichkeiten einführen, mit denen man die Güte eines Modells beurteilen kann.

## Multiple lineare Regression

Wir betrachten die Situation, dass mehrere erklärende Variablen  $x_1, x_2, \dots, x_p$  vorliegen. Das **multiple lineare Modell** besitzt dann die folgende Form (vgl. Abschnitt 8.2.2 in [3]):

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 \dots + \beta_p x_p + \epsilon.$$

Die abhängige Variable  $y$  lässt sich demnach als eine **Linear-kombination** der unabhängigen Variablen  $x_1, x_2, \dots, x_p$  ausdrücken. Aus dieser Tatsache ergibt sich auch der Name **lineares Modell**. Alle Variablen sind hier skalar. Kategoriale unabhängige Variablen werden in so genannte Dummy-Variablen (0 bis 1 Variablen) umgewandelt (vgl. Abschnitt 8.2.8 in [3]). So werden aus einer kategorialen Variablen mit  $k$  Kategorien dann  $k$  Dummy-Variablen, wobei nur  $k-1$  dieser Variablen ins Modell aufgenommen werden, da sich eine der Variablen unmittelbar aus den anderen  $k-1$  Variablen ergibt. Sind alle  $p$ -unabhängigen Variablen kategorial, bezeichnen wir dies als **p-Weg ANOVA** (ANalysis Of VAriance). Werden im Fall der ANOVA zur Adjustierung zusätzliche metrische Variablen (Kovariablen) ins Modell aufgenommen, so spricht man auch von **ANCOVA** (ANalysis of COVariance). Das Augenmerk liegt im Fall der ANCOVA wie im Fall der ANOVA auf den kategorialen Variablen.

### Die üblichen Voraussetzungen für das multiple lineare Modell sind:

- (0) Es gibt einen inhaltlich begründeten Zusammenhang zwischen  $x_1, x_2, \dots, x_p$  und  $y$ ; d. h.,  $y$  ist eine Funktion von  $x_1, x_2, \dots, x_p$ .
- (1) Die Varianz der  $y$ -Werte ist unabhängig von den Regressoren  $x_1, x_2, \dots, x_p$  und konstant; d. h.  $\text{Var}(y \mid x_1, x_2, \dots, x_p) = \sigma^2$ .
- (2) Die Beobachtungen sind voneinander (stochastisch) unabhängig; d. h., es liegt keine Zeitreihe vor.
- (3) Für die Berechnung des Schätzers wird zusätzlich benötigt, dass der Erwartungswert des Zufallsfehlers  $\epsilon$  gleich 0 ist ( $E(\epsilon) = 0$ ) und die Varianz gleich  $\sigma^2$  ist ( $\text{Var}(\epsilon) = \sigma^2$ ).
- (4) Für die Berechnung von Konfidenzintervallen und statistischen Tests wird zusätzlich vorausgesetzt, dass der Zufallsfehler normalverteilt ist.

Falls Abweichungen von den Voraussetzungen (0) bis (4) vorliegen, so kann man versuchen, diese Abweichungen durch

**Transformationen der Variablen** auszugleichen. Für die Transformation der Variablen kommt im Prinzip jede beliebige Funktion in Frage. Eine ganze Reihe von möglichen Transformationen sind etwa im Paket BestNormalize [5] für die Statistiksoftware R [6] enthalten.

Man spricht von einem **multivariaten linearen Modell**, wenn man es nicht mit skalaren, sondern mit vektorwertigen Variablen zu tun hat. Man nennt dies auch **allgemeines lineares Modell**. Dieses Modell muss man unterscheiden von einem **generalisiert linearen Modell**, bei dem die sogenannte Linkfunktion den linearen Zusammenhang zwischen der abhängigen Variablen  $y$  und den unabhängigen Variablen  $x_1, x_2, \dots, x_p$  herstellt. Diese beiden Modelle werden wir hier jedoch nicht genauer betrachten und verweisen stattdessen auf eine Vielzahl von Lehrbüchern, die es dazu gibt [7,8,9].

Wie bereits erwähnt, lässt sich das Bestimmtheitsmaß  $R^2$  zum Beispiel durch die Aufnahme weiterer Variablen erhöhen. Aus diesem Grund sollte man beim Vergleich von zwei Modellen, die unterschiedlich viele Variablen beinhalten, nicht das  $R^2$  heranziehen. Besser geeignet ist das folgende adjustierte  $R^2$  [10]:

$$R_{\text{adj}}^2 = 1 - (1 - R^2) \frac{n - 1}{n - p - 1} = R^2 - (1 - R^2) \frac{n - 1}{n - p - 1}.$$

Die Anzahl der Variablen  $p$  sowie die Stichprobengröße  $n$  werden hier zusätzlich berücksichtigt. Sollten zwei Modelle das gleiche  $R^2$  aufweisen, aber unterschiedlich viele Variablen beinhalten, so hat das Modell mit der geringeren Anzahl von Variablen das höhere  $R_{\text{adj}}^2$ . Weitere Kriterien, die zum Vergleich von Modellen herangezogen werden können, sind die **Mallows' Cp Statistik** [11]

$$C_p = \frac{1}{n} (RSS + 2 p \hat{\sigma}^2),$$

wobei  $\hat{\sigma}^2$  die Varianz der Residuen ist. Unter der Annahme (4) ist die Mallows' Cp Statistik äquivalent zum **Akaike Informationskriterium (AIC)** [12], welches definiert ist als

$$\text{AIC} = -2 \log(L) + 2p,$$

wobei  $L$  für das Maximum der Likelihood Funktion steht. Ein weiteres häufig verwendetes Kriterium ist das **Bayessche Informationskriterium (BIC)** [13]

$$\text{BIC} = \frac{1}{n} (RSS + \log(n) p \hat{\sigma}^2),$$

bei dem der Faktor 2 in der Mallows' Cp Statistik durch  $\log(n)$  ersetzt ist. Da  $\log(n) > 2$  für  $n > 7$ , werden Modelle mit mehr Variablen vom BIC-Kriterium stärker „bestraft“ als von der Cp Statistik. Bei allen drei Statistiken ist das Modell mit den kleineren Werten besser.

## Phänomene im Zusammenhang mit der linearen Regression

Im Zusammenhang mit Regressionsanalysen zeigen sich verschiedene Phänomene, deren Ursache und Bedeutung man sich bewusst sein sollte.

Ein erstes Phänomen, welches man beobachten kann, ist die sogenannte **Regression zur Mitte** (regression towards the mean/mediocrity), dessen Entdeckung man meist Francis Galton (1822–1911) zuschreibt [14]. Er beobachtete, dass kleine Väter relativ gesehen größere Söhne haben und umgekehrt, dass große Väter relativ gesehen kleinere Söhne haben. Das Phänomen tritt immer dann auf, wenn wir Messungen haben, die eine gewisse zufällige Variabilität aufweisen. Führt man eine Messung durch und erhält ein Ergebnis, welches weit vom (unbekannten) Mittel entfernt liegt, dann ist es wahrscheinlich, dass man in einer Wiederholungsmessung ein Ergebnis bekommt, welches näher beim (unbekannten) Mittel liegt. Dieser Effekt lässt sich in vielen Studien beobachten, in denen Patient:innen aufgrund sehr hoher oder sehr niedriger Ausgangswerte in die Studie eingeschlossen wurden. Ähnliches gilt auch für kleine Studien, in denen große Effekte gefunden wurden. Werden diese Studien mit größeren Fallzahlen wiederholt, so ergeben sich oft deutlich kleinere Effekte [15]. Die Regression zum Mittel ist ein rein statistischer Effekt ohne kausale Ursache. Man sollte demnach auch nicht nach einer Ursache suchen.

Ein zweites Phänomen ist das sogenannte **Simpson Paradoxon**. Es wurde von Simpson (1951) [16] im Zusammenhang mit Kontingenztafeln [17] beschrieben, kann jedoch auch im Rahmen von Regressionsanalysen und jeglichen Analysen mit multiplen Variablen auftreten. Wird eine wichtige Variable, wie etwa relevante Untergruppen, nicht berücksichtigt, kann dies zu völlig falschen Ergebnissen führen. In komplexen Systemen, wie wir diese in der Biologie und Medizin betrachten, ist es schwierig alle Variablen zu messen, geschweige denn überhaupt zu kennen. Damit kann man in solchen Situationen dieses Paradoxon nie ganz ausschließen. Entsprechend sollte man daher die Ergebnisse immer vorsichtig interpretieren.

Ein drittes Phänomen, welches im Zusammenhang mit der linearen Regression möglich ist, ist die sogenannte **Multikollinearität** (vgl. Abschnitt 8.2.3 in [3]). Diese tritt dann auf, wenn es eine hohe (multiple) Korrelation zwischen den unabhängigen Variablen gibt. Dieses Phänomen kann man nahezu immer in mehr oder weniger starker Form beobachten, da eine gewisse Korrelation zwischen den unabhängigen Variablen typisch ist, da diese Variablen oft ähnliche Informationen über die abhängige Variable enthalten. Falls eine Multikollinearität vorliegt, können kleine Änderungen in den Daten zu großen Veränderungen bei den geschätzten Koeffizienten führen. Im Gegensatz dazu hat eine Multikollinearität oft nur einen sehr kleinen Effekt auf die vorhergesagten Werte  $\hat{y}_i$ . Das bedeutet, dass auch bei Vorliegen einer Multikollinearität das Modell immer noch brauchbare Vorhersagen liefern kann. Jedoch sollte man bei der Interpretation der geschätzten Koeffizienten und des Modells selbst sehr vorsichtig vorgehen. Liegt eine Multikollinearität vor, so kann man diese auflösen, indem man die Variable, die diese verursacht, aus dem Modell entfernt.

Für das Aufspüren des Verursachers einer Multikollinearität kann man verschiedene Kriterien heranziehen. Man kann **paarweise Korrelationen** zwischen den unabhängigen Variablen berechnen oder den **Varianzinflationsfaktor (VIF)** bestimmen. Der VIF ergibt sich, indem man anstelle von  $y$  der Reihe

nach alle  $x_j$  ( $j = 1, 2, \dots, p$ ) als abhängige Variablen verwendet und die verbleibenden Variablen  $x_i$  ( $i \neq j$ ) als unabhängige Variablen nutzt. Dies führt auf die Bestimmtheitsmaße  $R_j^2$  und wir erhalten

$$VIF = (1 - R_j^2)^{-1}.$$

Falls  $VIF > 10$ , liegt möglicherweise eine Multikollinearität vor. Falls  $VIF > 100$ , kann man relativ sicher von einer Multikollinearität ausgehen. Eine weitere Möglichkeit besteht darin, die sogenannte **Kondition des linearen Modells** zu berechnen. Falls diese im Bereich von 10–30 liegt, spricht man von einer moderaten Multikollinearität. Ist diese  $> 100$ , so liegt eine starke Multikollinearität vor.

## Modellwahl

Heute werden in Studien in der Regel eine Vielzahl von Variablen erhoben, weshalb man sich häufig damit beschäftigen muss, welche der Variablen wirklich im Modell berücksichtigt werden sollen. Hierfür sollten in erster Linie fachliche Überlegungen herangezogen werden. Es gibt aber auch verschiedene statistische Lösungen (vgl. Abschnitt 8.2.7 in [3]).

### Zum Beispiel kann man folgende Ansätze verwenden:

- Betrachte alle möglichen Teilmodelle und wähle das „beste“ ( $2^p - 1$  Modelle!).
- Starte mit dem Nullmodell und füge Schritt für Schritt jeweils die „beste“ Variable hinzu bis das „optimale“ Modell erreicht ist (Vorwärts-Einschluss).
- Starte mit dem Modell mit allen Variablen und entferne Schritt für Schritt jeweils die „schlechteste“ Variable bis das „optimale“ Modell erreicht ist (Rückwärts-Elimination).
- Kombiniere Vorwärts-Einschluss und Rückwärts-Elimination.

Als Kriterien zur Auswahl des besten Modells können das adjustierte  $R^2$ , die Mallows' Cp Statistik, das AIC- oder BIC-Kriterium oder auch statistische Tests herangezogen werden. Wendet man diese Ansätze auf den gesamten vorliegenden Datensatz an, so muss man davon ausgehen, dass die Ergebnisse für das ausgewählte Modell zu optimistisch sind und es auch Variablen enthält, die nur zufällig als wichtig eingestuft wurden und keinen echten Erklärungswert haben. Auch ist es möglich, dass wichtige Variablen ausgeschlossen wurden, da diese zusätzlich zu den bereits im Modell enthaltenen Variablen keinen neuen Erklärungswert liefern. Man spricht in diesem Zusammenhang auch von **Wiedereinsetzbias (resubstitution bias)** und **Modellwahlbias (model selection bias)**, da die Modelle auf Basis derselben Daten bewertet werden, mit denen sie auch berechnet wurden (resubstitution) und aus vielen Modellen ein bestes ausgewählt (model selection) wird [18]. Man kann diese beiden Fehlerquellen kontrollieren, wenn zusätzlich sogenannte **Resamplingmethoden** wie **Bootstrap** oder **Kreuzvalidierung** zum Einsatz kommen. Dies wird auch **interne Validierung** genannt. Es kann für die Modellbewertung auch ein unabhängiger Datensatz aus einer separaten

Studie herangezogen werden. In diesem Fall spricht man von **externer Validierung** [18].

Eine alternative Herangehensweise stellt die **Lasso Regression** [19] dar, bei der durch einen zusätzlichen Strafterm bei der Bestimmung des optimalen Modells die Gefahr reduziert wird, dass es zu einer sogenannten **Überanpassung (overfitting)** kommt und zu den oben genannten Verzerrungen.

## Modelldiagnostik

Nachdem das (optimale) Modell bestimmt wurde, sollte man prüfen, ob die Voraussetzungen (0)-(4) für dieses Modell erfüllt sind, bevor man das Modell im Detail interpretiert. Sollten nämlich eine oder mehrere der Voraussetzungen verletzt sein, so kann die Bestimmung der Koeffizienten oder auch die Berechnung von Tests oder Konfidenzintervallen fehlerhaft sein. Für die Überprüfung der Voraussetzungen stehen verschiedene statistische Tests zur Auswahl. Hierbei sollte man jedoch beachten, dass diese Tests meist nur bestimmte und nicht etwa jegliche Art von Abweichungen erkennen. Die Tests besitzen demnach nur eine begrenzte Power zur Aufdeckung von Abweichungen. Daher ist es üblich, die Diagnostik unter Verwendung von graphischen Darstellungen durchzuführen, wobei hierfür in erster Linie die Residuen herangezogen werden (vgl. Abschnitt 8.2.4 in [3]). Wir werden hierauf im Rahmen des folgenden Beispiels genauer eingehen.

## Beispiel

Für ausführliche Beispiele zum t-Test und zur 1-Weg ANOVA verweisen wir auf unsere Tutorien hierzu [1,2]. Wir erweitern das Beispiel aus [2] zur glomerulären Filtrationsrate (GFR) nach einer Herzoperation mit extrakorporaler Zirkulation (EKZ) zu einer ANCOVA, indem wir zusätzlich auf die GFR-Werte vor der OP adjustieren. Es liegen drei Gruppen vor, wobei eine Gruppe zum „venösen Pooling“ Nitroprussid und eine zweite Gruppe alternativ Nitroglycerin erhielt. Eine Gruppe war ohne Intervention. Die Gruppen bestehen zusammen aus 614 Pa-

tient:innen (Nitroprussid: 219, Nitroglycerin: 176, ohne Intervention: 219), wobei durch fehlende Werte nur 592 Patient:innen in die ANCOVA eingehen (Nitroprussid: 214, Nitroglycerin: 167, ohne Intervention: 211). Wir erhalten einen signifikanten Unterschied zwischen den Gruppen ( $p = 1.2 \times 10^{-12}$ ), wobei  $R^2 = 0.785$  und  $R_{adj}^2 = 0.784$ . Jedoch können wir anhand der beiden Darstellungen der Residuen in Abbildung 1 erkennen, dass die Annahme einer konstanten Varianz verletzt ist. Dies sieht man daran, dass die Residuen im linken Plot eine keilförmige Punktwolke bilden (Streuung nimmt von links nach rechts zu) und die Kurve im rechten Plot von links nach rechts deutlich ansteigt. Man spricht in diesem Fall auch von einer **Heteroskedastizität** der Residuen.




Abb. 2: qq-Plot der Residuen (erstellt mit dem Paket qqplotr [21] der Statistiksoftware R [6])

Der qq-Plot in Abbildung 2, in dem die empirischen Quantile der standardisierten Residuen mit den theoretischen Quantilen der Standardnormalverteilung verglichen werden, zeigt außerdem, dass gewisse Abweichungen von der Normalverteilung vorliegen.

Wir sollten daher mit der Interpretation der Ergebnisse vorsichtig sein. Eine Möglichkeit, mit dieser Situation umzugehen, besteht darin, eine geeignete Transformation für die Daten zu finden, welche die Heteroskedastizität und die Abweichungen von der Normalverteilung reduziert oder idealerweise sogar komplett entfernt. Das Paket `bestNormalize` [6] liefert im vorliegenden Fall die Quadratwurzel als eine mögliche Transformation. Wir wiederholen die Berechnungen, wobei wir die Quadratwurzel der GFR-Werte




Abb. 1: Plots der Residuen (erstellt mit dem Paket `performance` [20] der Statistiksoftware R [6])






Abb. 3: Plots der Residuen nach Verwendung der Quadratwurzel als Transformation (erstellt mit dem Paket `performance` [20] der Statistiksoftware R [6])

(prä- und post-OP) verwenden. Es ergibt sich erneut ein signifikanter Unterschied zwischen den Gruppen ( $p = 1.4 \times 10^{-12}$ ), wobei  $R^2 = 0.813$  und  $R_{adj}^2 = 0.812$ . Die Modellanpassung hat sich durch die Transformation demnach verbessert. Die Darstellungen der Residuen in Abbildung 3 zeigen außerdem, dass sich die Heteroskedastizität deutlich verringert hat. Auch die Abweichungen von der Normalverteilung haben sich deutlich reduziert, wie in Abbildung 4 zu sehen ist.




Abb. 4: qq-Plot der Residuen nach Verwendung der Quadratwurzel als Transformation (erstellt mit dem Paket `qqplotr` [21] der Statistiksoftware R [6])

Wir gehen daher davon aus, dass die Voraussetzungen (0)–(4) nach der Transformation zumindest näherungsweise erfüllt sind und wir die Ergebnisse der linearen Regressionsanalyse für den Gruppenvergleich heranziehen können. Da wir es mit drei Gruppen zu tun haben, führen wir zusätzlich Post-hoc-Tests durch, um die Unterschiede zwischen den Gruppen

genauer zu untersuchen. Wir verwenden hierfür das Paket `emmeans` [22]. Wir erhalten signifikante Unterschiede bei allen drei paarweisen Vergleichen (Nitroprussid vs. Nitroglycerin:  $p = 0.0001$ , Nitroprussid vs. ohne Intervention:  $p < 0.0001$ , Nitroglycerin vs. ohne Intervention:  $p = 0.004$ ).

Abbildung 5 zeigt die geschätzten sogenannten marginalen Mittelwerte der post-OP GFR-Werte, die aus den Ergebnissen der ANCOVA berechnet wurden, und die zugehörigen 95 %-Konfidenzintervalle. Wir sehen, dass die post-OP GFR-Werte von der Nitroprussid-Gruppe über die Nitroglycerin-Gruppe zur Gruppe ohne Intervention signifikant ansteigen. Im Fall der 1-Weg ANOVA [2] zeigten sich nur

im Vergleich der Nitroprussid-Gruppe und der Nitroglycerin-Gruppe sowie der Nitroprussid-Gruppe und der Gruppe ohne Intervention signifikante Unterschiede. Dies liegt vermutlich daran, dass die zusätzliche Adjustierung auf die prä-OP-Werte die Variabilität reduziert und so die Power der Analyse erhöht.




Abb. 5: Geschätzte marginale Mittelwerte und 95 %-Konfidenzintervalle für die post-OP GFR-Werte (erstellt mit dem Paket `emmeans` [22] der Statistiksoftware R [6])

Wir verzichten auf komplexere Beispiele zur linearen Regression, da dies den Rahmen dieses Tutoriums deutlich sprengen würde, und empfehlen in diesem Fall auch immer einen Statistiker zu Rate zu ziehen.

## Zusammenfassung

Die lineare Regression stellt ein sehr flexibles statistisches Verfahren dar, welches in vielen Fällen angewendet werden kann. Durch den Einsatz von Variablentransformationen lässt sich ihr Anwendungsbereich sogar noch weiter ausdehnen. Insbesondere die Varianz- und Kovarianzanalyse, die Spezi-

alfälle der multiplen Regression sind, finden in vielen praktischen Studien, in denen es oft um den Vergleich von Gruppen geht, breite Anwendung. Bevor die Ergebnisse einer linearen Regressionsanalyse im Detail interpretiert werden, sollte immer eine gründliche Modelldiagnostik durchgeführt und damit die Voraussetzungen an das lineare Modell geprüft werden. Insbesondere das Bestimmtheitsmaß  $R^2$  sollte immer mit großer Vorsicht interpretiert werden, da es leicht zu manipulieren ist. Entsprechende Alternativen wie das adjustierte  $R^2$ , die Mallows' Cp Statistik, AIC- oder BIC-Kriterium sollten bei der Modellwahl zusätzlich berücksichtigt werden. Auch sollte man bei der Interpretation und Diskussion der Ergebnisse typische Phänomene beachten, die im Zusammenhang mit der linearen Regression auftreten können. In aktuellen Studien werden mehr und mehr Variablen erhoben. Wird in einem solchen Fall eine statistische Modellwahl durchgeführt, so sollte dies mit großer Sorgfalt und unter Verwendung einer internen oder externen Validierung erfolgen, damit es möglichst nicht zu verzerrten Ergebnissen kommt. Wir empfehlen außerdem bei komplexen linearen Regressionsanalysen immer einen Statistiker zu konsultieren, um methodisch falsche Vorgehensweisen und Fehlinterpretationen zu vermeiden.

## Literatur

1. Kohl M, Münch F. Statistik Teil 8: t-Tests und Alternativen. *Kardiotechnik*, 2023(4): 143-147.
2. Kohl M, Münch F. Statistik Teil 9: Die 1-Weg ANOVA. *Die Perfusionologie*, 2024(1): 15-20.
3. Hedderich J, Sachs L. *Angewandte Statistik*, 2020. Methodensammlung mit R. 17. Auflage, Springer-Verlag.

4. Kohl M, Münch F. Statistik Teil 4: Korrelationen. *Kardiotechnik*, 2022(4): 146-149.
5. Peterson RA. Finding optimal normalizing transformations via bestNormalize. *The R Journal*, 2021. 13:1, 310-329. <https://doi.org/10.32614/RJ-2021-041>.
6. R Core Team. R: A language and environment for statistical computing. R Foundation for Statistical Computing, 2024. Vienna, Austria. URL <https://www.R-project.org/>.
7. Harrell FE. Regression modelling strategies. With applications to linear models, logistic and ordinal regression, and survival analysis, 2015. Second Edition. Springer.
8. Agresti A. Foundations of linear and generalized linear models, 2015. Wiley.
9. Dunn PK, Smyth GK. Generalized linear models with examples in R. Springer, 2018.
10. Mordecai E. Methods of correlation analysis. Wiley, 1930.
11. Mallows CL. Some comments on CP. *Technometrics*, 1973. 15 (4): 661-675. <https://doi.org/10.2307/1267380>
12. Akaike H. A new look at the statistical model identification. *IEEE Transactions on automatic control*, 1974. 19 (6): 716-723. <https://doi.org/10.1109/TAC.1974.1100705>.
13. Schwarz GE (1978). Estimating the dimension of a model. *Annals of Statistics*, 6 (2): 461-464. <https://doi.org/10.1214/aos/1176344136>.
14. Krashniak A, Lamm E. Francis Galton's regression towards mediocrity and the stability of types. *Studies in History and Philosophy of Science*, 2021. 86: 6-19. <https://doi.org/10.1016/j.shpsa.2020.12.008>.
15. Button KS, Ioannidis JP, Mokrysz C, Nosek BA, Flint J, Robinson ES, Munafò MR. Power failure: why small sample size undermines the reliability of neuroscience. *Nat Rev Neurosci*, 2013. 14(5): 365-76. <https://doi.org/10.1038/nrn3475>.
16. Simpson EH. The Interpretation of interaction in contingency tables. *Journal of the Royal Statistical Society*, 1951. Ser. B. 13: 238-241. <https://doi.org/10.1111/j.2517-6161.1951.tb00088.x>.
17. Kohl M, Münch F. Statistik Teil 5: Kontingenzkoeffizienten. *Kardiotechnik*, 2023(1): 12-14.
18. Kerr KF, Meisner A, Thiesen-Philbrook H, Coca SG, Parikh CR. RIGOR: reporting guidelines to address common sources of bias in risk model development. *Biomark Res*. 2015 Jan 24;3(1):2. doi: 10.1186/s40364-014-0027-7.
19. Tibshirani R. Regression shrinkage and selection via the lasso. *Journal of the Royal Statistical Society*, 1996. Series B (methodological) 58 (1): 267-88. <https://doi.org/10.1111/j.2517-6161.1996.tb02080.x>.
20. Lüdtke D, Ben-Shachar MS, Patil I, Waggoner P, Makowski D. Performance: An R package for assessment, comparison and testing of statistical models. *Journal of Open Source Software*, 2021. 6(60), 3139. <https://doi.org/10.21105/joss.03139>.
21. Almeida A, Loy A, Hofmann H (2018). ggplot2 Compatible Quantile-Quantile Plots in R. *The R Journal*, 10(2), 248-261. <https://doi.org/10.32614/RJ-2018-051>.
22. Lenth R. emmeans: Estimated marginal means, aka least-squares means, 2024. R package version 1.10.4.

## 53. Internationale Jahrestagung der Deutschen Gesellschaft für Kardiotechnik und 16. Fokustagung Herz der DGTHG und DGfK, 8.–10. November 2024 in Münster

Münster die Dritte: Nach drei Jahren außergewöhnlicher Gastfreundschaft verabschiedet sich die Deutsche Gesellschaft für Kardiotechnik (DGfK) mit zukunftsweisenden Veränderungen und vielen herausragenden Geschichten aus der nordrhein-westfälischen Friedensstadt.

„Was verbinden Sie mit Münster?“ Diese Frage dürfte für viele unweigerlich mit dem kultigen Ermittlerteam der sonntagabendlichen Krimireihe „Tatort“ verknüpft sein. Der diesjährige



Tagungspräsident Sven Maier (Freiburg) und die Tagungspräsidentin Prof. Dr. Gloria Färber (Homburg) griffen diese Assoziation auf und stellten die Verbindung zur 53. Internationalen Jahres-

Abb. 1: Tagungspräsidentin Prof. Gloria Färber (DGTHG) und Tagungspräsident Sven Maier (DGfK)

tagung der Deutschen Gesellschaft für Kardiotechnik und der 16. Fokustagung Herz der DGTHG und DGfK her. Während der Eröffnungsfeier am Freitagabend betonten sie, dass auch in der Herzmedizin ein interdisziplinäres Team zusammenarbeitet, um Ursachen zu ermitteln und jeden Fall bestmöglich therapieren zu können.

Im Anschluss an diese einleitenden Worte folgte ein besonderes Highlight der Eröffnungsfeier: Dr. med. Jan M. Federspiel aus der Rechtsmedizin Homburg zog das Publikum mit seinem Vortrag „Fakten-Check – Tatort Herzmedizin“ in den Bann. Mit einer gelungenen Mischung aus präziser Analyse und humorvollen Einblicken nahm Dr. Federspiel Ausschnitte aus der beliebten Krimireihe unter die Lupe. Er deckte sowohl medizinische Ungenauigkeiten als auch die idealisierte Darstellung der Rechtsmedizin auf.

Sein lebendiger Vortrag sorgte für Begeisterung im Publikum und setzte einen mitreißenden Startschuss für die diesjährige Jahrestagung. Im Anschluss wurde den Teilnehmerinnen und Teilnehmern ein reichhaltiges Angebot an Speisen und Getränken offeriert, als Stärkung für den darauffolgenden Besuch der Industrieausstellung. Von der Kardioplegie über Filtersysteme, HLM-Sets, Überwachungsgeräte für die Gold Directed Perfusion bis hin zu Assist Devices wie Impella, Berlin Heart und ECMO, gab es wieder viel zu entdecken. Besonders hervorzuheben sind zwei Herz-Lungen-Maschinen, die von den Kongress-