

Die Perfusionologie stellt in der Rubrik Tutorials in Folge relevante Methoden für wissenschaftliche Arbeiten zur klinischen Perfusion und technischen Medizin vor.

Statistik Teil 14: Logistische Regression



Prof. Dr. Matthias Kohl
Department of Health, Medical and Life Sciences
Institute of Precision Medicine
Hochschule Furtwangen
Jakob-Kienzle-Str. 17, 78054 Villingen-Schwenningen (Germany)
Phone: +49 (0) 7720 307-4635
E-Mail: matthias.kohl@hs-furtwangen.de
www.hs-furtwangen.de · www.life-data-science.org

M. Kohl, F. Münch

Einführung

In der Medizin und Epidemiologie spielen binäre/dichotome Response-Variablen eine sehr wichtige Rolle. Sie dienen zum Beispiel dazu, um Mortalität, Letalität, Inzidenz oder Prävalenz zu untersuchen. Falls die Response von gewissen erklärenden Variablen abhängt, führt uns dies auf die logistische Regressionsanalyse. Wir haben diese bereits kurz in einem vorangegangenen Tutorial angesprochen [1]. Darüber hinaus wird die logistische Regression auch häufig für die binäre Klassifikation verwendet. Wir werden in diesem Tutorial kurz das multiple logistische Modell vorstellen und auf wichtige Aspekte eingehen, die in der Praxis zu beachten sind. Zur Demonstration führen wir außerdem anhand eines Praxisbeispiels eine logistische Regressionsanalyse durch.

Multiple logistische Regression

Wie in [1] besprochen, führt uns die Betrachtung eines binären Merkmals Y auf die Bernoulli- oder Binomial-Verteilung, wobei die Erfolgswahrscheinlichkeit $P(Y = 1) = p \in [0, 1]$ unbekannt ist. Wollen wir den Einfluss von $k \geq 1$ unabhängigen Variablen auf p untersuchen, so können wir hierfür nicht den direkten Modellansatz

$$p = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_k x_k$$

verwenden, da die rechte Seite der Gleichung unbeschränkt ist. Wenn wir hierauf aber die Transformation

$$f(u) = \frac{e^u}{1 + e^u}$$

anwenden, welche die reellen Zahlen auf das Intervall $(0, 1)$ abbildet, ändert sich die Situation. Wir erhalten

$$p = \frac{e^{\beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_k x_k}}{1 + e^{\beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_k x_k}} = \frac{1}{1 + e^{-(\beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_k x_k)}}$$

Die Funktion f entspricht einer **logistischen Funktion** und ergibt sich auch als **Verteilungsfunktion der logistischen Ver-**

Fazitbox

Pro und Contra logistische Regression:

Pro

- Analog zum linearen Modell lassen sich ANOVA- und ANCOVA-Modelle definieren, wobei man anstelle der Varianz die Devianz betrachtet.
- Anstelle des Bestimmtheitsmaßes R^2 können im Fall der logistischen Regression verschiedene Pseudo- R^2 zur Untersuchung der Modellanpassung verwendet werden. Alternativ hierzu sind auch AIC und BIC möglich.
- Die logistische Regression kann auch für die binäre Klassifikation Anwendung finden.

Contra

- Ein logistisches Modell sollte immer einer gründlichen Modelldiagnostik unterzogen werden.
- Das Simpson Paradoxon und Multikollinearität sind auch bei der logistischen Regression zu beachten und sollten bei der Interpretation und Diskussion der Ergebnisse einbezogen werden.
- Wird eine statistische Modellwahl durchgeführt, so sollte dies mit großer Sorgfalt und unter Verwendung einer internen oder externen Validierung erfolgen.

teilung. Manchmal wird diese auch als **expit-Transformation** bezeichnet in Analogie zu ihrer Umkehrfunktion

$$f^{-1}(p) = \log \left(\frac{p}{1-p} \right),$$

welche üblicherweise **logit-Transformation** genannt wird. Nutzen wir diesen Zusammenhang, so ergibt sich

$$\text{logit}(p) = \log \left(\frac{p}{1-p} \right) = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_k x_k$$

das **multiple logistische Regressionsmodell** (vgl. Abschnitt 8.4 in [2]). Der Ausdruck

$$\frac{p}{1-p} = \frac{P(Y=1)}{1-P(Y=1)} = \frac{P(Y=1)}{P(Y=0)}$$

wird auch **Chance** oder **Odds** genannt. Bei der logistischen Regression handelt es sich demnach um ein **lineares Modell für die log-Odds**. Die logistische Regression ist außerdem ein spezielles **generalisiert lineares Modell**, wobei man in diesem Zusammenhang die logit-Transformation auch als Linkfunktion bezeichnet. Die Parameter $\beta_0, \beta_1, \dots, \beta_k$ können dabei mit Hilfe der Maximum-Likelihood-Methode geschätzt werden, wobei hierfür ein iteratives Verfahren zum Einsatz kommt, das sogenannten **Fisher-Scoring**. Die Interpretation der Koeffizienten ist im Fall der logistischen Regression etwas schwieriger und man wendet hierfür üblicherweise die e-Funktion auf das Modell an (vgl. Abschnitt

8.4.3 in [2]). Dies führt uns auf

$$\text{Odds}(x_1, \dots, x_k) = e^{\beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_k x_k}$$

Ändern wir den Wert einer unabhängigen Variable x_i um eine Einheit und lassen die anderen unabhängigen Variablen unverändert, so erhalten wir

$$\frac{\text{Odds}(x_1, \dots, x_i + 1, \dots, x_k)}{\text{Odds}(x_1, \dots, x_i, \dots, x_k)} = \frac{e^{\beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_i(x_i + 1) + \dots + \beta_k x_k}}{e^{\beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_i x_i + \dots + \beta_k x_k}} = e^{\beta_i}$$

Die Größe e^{β_i} beschreibt demnach das **Chancenverhältnis (Odds-Ratio)** bei der Veränderung der Variable x_i um eine Einheit. Da die anderen $k-1$ unabhängigen Variablen im Modell unverändert bleiben, spricht man auch von einer **adjustierten Odds-Ratio**, adjustiert auf die anderen $k-1$ unabhängigen Variablen. Der Koeffizient e^{β_i} wird auch als **Einfluss- oder Effekt-Koeffizient** bezeichnet. Erhält man einen Wert <1 , so hat die Veränderung einen negativen Einfluss/Effekt auf die Odds-Ratio. Ein positiver Einfluss/Effekt auf die Odds-Ratio liegt vor, falls $e^{\beta_i} > 1$ ist.

Das logistische Modell basiert auf weniger **Voraussetzungen** als das lineare Modell (vgl. [3]). Im Wesentlichen muss es einen inhaltlich begründeten (linearen) Zusammenhang zwischen den Regressoren und der log-Odds geben, wobei die Beobachtungen voneinander (stochastisch) unabhängig sein müssen (keine Zeitreihe).

In der logistischen Regression tritt an die Stelle der Residuenquadrate RSS (residual sum of squares) der linearen Regression (vgl. [3]) die sogenannte **Devianz** (vgl. Abschnitt 8.4.1 in [2]). Folglich spricht man dann auch von einer **Devianzanalyse** (analysis of deviance) anstatt von einer Varianzanalyse (analysis of variance). Die Nullhypothese $H_0: \beta_i = 0$ kann (asymptotisch) mit Hilfe eines **z-Tests** untersucht werden. Alternativ kann hierfür auch ein sogenannter **Likelihood-Verhältnistest** (ein χ^2 -Test), der auf der Devianz basiert, herangezogen werden.

Es können für logistische Modelle analog zum linearen Modell auch **ANOVA- und ANCOVA-Modelle** definiert werden, wobei anstelle der Varianz die Devianz analysiert wird.

Für die **Modelldiagnostik** verwendet man nicht die Residuen wie bei der linearen Regression [3], sondern die sogenannten **Devianz- und Pearson-Residuen**. Wir verzichten hier auf die Definition dieser Residuen und verweisen stattdessen auf Abschnitt 8.4.5 in [2]. Falls das Modell korrekt ist, sollten diese Residuen zumindest näherungsweise einer Normalverteilung folgen (vgl. Abschnitt 8.4.5 in [2]).

Da das Bestimmtheitsmaß R^2 auf der Varianz basiert, kann es im Fall der logistischen Regression nicht zur Beurteilung der Güte der Anpassung herangezogen werden. Stattdessen kommen hierfür sogenannte **Pseudo-Bestimmtheitsmaße** R^2 zum Einsatz, welche sich aus der Devianzanalyse ergeben (vgl. Abschnitt 8.4.6 in [2]). Man vergleicht die **Likelihoods (L)** oder **log-Likelihoods (logL)** von Modell und Nullmodell (Modell mit 0 Regressoren). Bekannte Pseudo-Bestimmtheitsmaße sind:

$$\text{Pseudo-}R^2 \text{ von McFadden} = R_F^2 = 1 - \frac{\log L(\text{Modell})}{\log L(\text{Nullmodell})} \quad [4]$$

$$\text{Pseudo-}R^2 \text{ von Cox und Snell} = R_{CS}^2 = 1 - \left(\frac{L(\text{Nullmodell})}{L(\text{Modell})} \right)^{2/n} \quad [5]$$

$$\text{Pseudo-}R^2 \text{ von Nagelkerke} = R_N^2 = \frac{R_{CS}^2}{1 - (L(\text{Nullmodell}))^{2/n}} \quad [6]$$

Eine weitere Alternative ist das **Pseudo- R^2 von Tjur** [7], welches ursprünglich von Tjur als Diskriminationskoeffizient (coefficient of discrimination) bezeichnet wurde:

$$R_T^2 = |\text{AM}(\hat{p}(Y = 1)) - \text{AM}(\hat{p}(Y = 0))|$$

Es wird in diesem Fall das arithmetische Mittel (AM) der vorhergesagten Wahrscheinlichkeiten für Beobachtungen mit $Y = 1$ mit dem AM der vorhergesagten Wahrscheinlichkeiten für Beobachtungen mit $Y = 0$ verglichen. Neben diesen Pseudo- R^2 -Werten können auch das **Akaike und das Bayessche Informationskriterium (AIC und BIC)** für den Vergleich von Modellen herangezogen werden [3].

Das **Simpson-Paradoxon** und **Multikollinearität** können auch im Rahmen einer logistischen Regressionsanalyse auftreten (vgl. [3]). Für die **Modellwahl** gibt es im Fall der logistischen Regression analoge Ansätze wie im Fall der linearen Regression, die mit ähnlichen Einschränkungen verbunden sind (vgl. [3]).

Da das logistische Regressionsmodell auch für die **binäre Klassifikation** verwendet werden kann, können zur Beurteilung der Ergebnisse auch die entsprechenden Methoden der binären Klassifikation wie etwa die Analyse der ROC (receiver operating characteristic)-Kurve herangezogen werden [8]. Dies geht jedoch über die Zielsetzung dieses Tutorials hinaus.

Beispiel

Wir greifen das Beispiel zur 30-Tage-Mortalität aus dem Tutorial 10 auf [1]. Wir betrachten nur Kinder mit hypoplastischem Linksherzsyndrom, die einer Herzoperation mit extrakorporaler Zirkulation unterzogen wurden. Des Weiteren betrachten wir nur die beiden Kardioplegieverfahren Custodiol (CCC) und pädiatrische Mikroplegie (MBC). Aus einem großen Datensatz mit 1061 Kindern erfüllen 45 Kinder diese Kriterien, wobei 10 der Kinder innerhalb von 30 Tagen nach der Operation (OP) verstarben. Da alle verstorbenen Kinder sehr jung waren (max. 12 Tage), schränken wir den Datensatz weiter ein und schließen nur Kinder ein, die bei der OP maximal 14 Tage alt waren. Dies reduziert den Datensatz auf 32 Kinder. Wir untersuchen mit Hilfe einer logistischen Regressionsanalyse den Einfluss des Kardioplegieverfahrens auf die 30-Tage-Mortalität, wobei wir auf die Ischämiezeit (in Minuten), den VIS-Score und das Gewicht (in Kilogramm) adjustieren. Bei 8 Kindern wurde CCC eingesetzt, wobei hiervon zwei verstorben sind. Im Fall von MBC sind 8 der 24 Kinder verstorben. Die Residuen in Abbildung 1 wirken zufällig und zeigen keine auffälligen Strukturen.




Abb. 1: Devianz- und Pearson-Residuen für das multiple logistische Regressionsmodell (erstellt mit dem Paket ggplot2 [9] der Statistiksoftware R [10])

Die qq-Plots der Residuen in Abbildung 2 bestätigen, dass wir zumindest näherungsweise von einer Normalverteilung der Residuen ausgehen können.

Für die Pseudo- R^2 -Maße erhalten wir durchweg recht ähnliche Werte: $R^2_F = 0,20$, $R^2_{CS} = 0,22$, $R^2_N = 0,31$ und $R^2_T = 0,22$. Die Werte deuten auf ein akzeptables Modell hin (vgl. Abschnitt 8.4.6 in [2]).

Sowohl einzeln betrachtet als auch im multiplen Regressionsmodell ergibt sich für das Kardioplegieverfahren (z-Test: $p = 0,506$, χ^2 -Test: $p = 0,494$) kein signifikanter Effekt auf die 30-Tage-Mortalität. Auch die Ischämiezeit (z-Test: $p = 0,355$, χ^2 -Test: $p = 0,345$, adj. OR (CI95): 2,19 (0,22 – 22,0)) und der VIS-Score (z-Test: $p = 0,675$, χ^2 -Test: $p = 0,672$, adj. OR (CI95): 0,99 (0,96–1,01)) haben keinen signifikanten Effekt auf die 30-Tage-Mortalität. Im Fall des Gewichts bewegt sich das Ergebnis an der Grenze zur Signifikanz (z-Test: $p = 0,053$, χ^2 -Test: $p = 0,031$, adj. OR (CI95): 0,09 (0,01 – 1,04)). Das 95 %-Konfidenzintervall (CI95) basiert auf der Normalverteilung und ist daher in Verbindung mit dem z-Test zu sehen. Ein um 1 kg höheres Gewicht könnte demnach unter Umständen die Chance, innerhalb 30 Tage nach der OP zu versterben, recht deutlich reduzieren. Wir gehen jedoch nicht davon aus, dass hier ein direkter Kausalzusammenhang zwischen dem Gewicht und der 30-Tage-Mortalität vorliegt, sondern dass

es einen oder mehrere Risikofaktoren für die Schwere der Erkrankung und dem damit verbundenen Mortalitätsrisiko gibt, die auch zu einem geringeren Gewicht führen.

Zusammenfassung

Die logistische Regression spielt in der Medizin und Epidemiologie eine wichtige Rolle. Es lassen sich analog zum linearen Modell ANOVA- und ANCOVA-Modelle definieren, die jedoch auf der Devianz anstelle der Varianz basieren. Man spricht deshalb auch von Devianz-Analyse. Zur Untersuchung der Modellanpassung können verschiedene Pseudo- R^2 -Maße verwendet werden, wobei auch AIC und BIC für Modellvergleiche zur Verfügung stehen. Häufig wird die logistische Regression auch für die binäre Klassifikation eingesetzt. In jedem Fall sollte ein gefittetes Modell immer einer gründlichen Modelldiagnostik unterzogen werden. Das Simpson-Paradoxon oder Multikollinearität können auch im Zusammenhang mit der logistischen Regression auftreten. Soll mit Hilfe einer statistischen Modellwahl ein möglichst gutes logistisches Regressionsmodell gefunden werden, so sollte dies mit großer Sorgfalt und unter Verwendung einer internen oder externen Validierung erfolgen, um ein Bias zu vermeiden. Generell empfehlen wir bei komplexen Regressionsanalysen immer einen Statistiker zu konsultieren.




Abb. 2: qq-Plots der Devianz- und Pearson-Residuen für das multiple logistische Regressionsmodell (erstellt mit dem R Paket qqplotr [11] der Statistiksoftware R [10])

Literatur

1. Kohl M, Münch F. Statistik Teil 10: Wichtige Tests für nominale Merkmale. Die Perfusionologie 2024(2): 57-62.
2. Hedderich J, Sachs L. Angewandte Statistik. Methodensammlung mit R. 17, 2020. Springer-Verlag.
3. Kohl M, Münch F. Statistik Teil 13: Lineare Regression. Die Perfusionologie 2025(1): 26-31.
4. McFadden D. Quantitative methods for analysing travel behaviour of individuals. Some recent developments. In: Hensher DA (Hg), Stopher PR (Hg): Behavioural travel modelling. Croom Helm, 1979: 279-318.
5. Cox DR, Snell EJ. Analysis of binary data. Chapman and Hall.1989.
6. Nagelkerke NJD. A note on a general definition of the coefficient of determination. Biometrika 1991; 78: 691-693.
7. Tjur T. Coefficients of determination in logistic regression models – A new proposal: The coefficient of discrimination. The American Statistician 2009. 63(4): 366-372.
8. Kohl M. Performance measures in binary classification. International Journal of Statistics in Medical Research 2012; 1(1): 79-81.
9. Wickham H. ggplot2: Elegant graphics for data analysis. 2016. Springer-Verlag New York.
10. R Core Team. R: A language and environment for statistical computing. R Foundation for Statistical Computing, 2025. Vienna, Austria. URL <https://www.R-project.org/>
11. Almeida A, Loy A, Hofmann H (2018). ggplot2 compatible quantile-quantile plots in R. The R Journal, 10(2), 248-261. <https://doi.org/10.32614/RJ-2018-051>.